Aprendizaje por Refuerzo en Breakout con DQN (Gymnasium + Stable-Baselines3)

Resumen

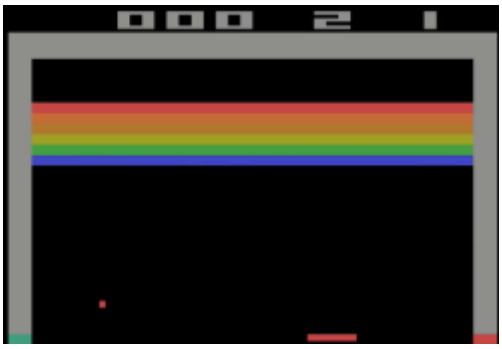

Se implementó un agente Deep Q-Network (DQN) para el entorno ALE/Breakout-v5 usando Gymnasium, ale-py y Stable-Baselines3 con CnnPolicy. El agente entrenó durante 20 millones de *timesteps*. La recompensa promedio por episodio pasó de ~1.0 en los primeros miles de pasos a ~35 cerca del final del entrenamiento, acompañado por un aumento en la duración de episodio hacia ~1000 pasos. Las corridas de evaluación muestran episodios con recompensas en el rango 16–45. Se incluyen gráficos de convergencia y distribución de recompensas.

Introducción

Breakout es un entorno clásico de Atari donde una paleta controla la trayectoria de una pelota para romper ladrillos y maximizar la recompensa. El objetivo es aprender una política que, a partir de observaciones visuales, seleccione acciones discretas (izquierda/derecha/noop/servir) que maximicen el retorno acumulado.

DQN, Gymnasium y SB3

Se eligió Deep Q-Network (DQN), una extensión de Q-Learning que aproxima la función de acción-valor con una red convolucional, emplea replay buffer para romper correlación temporal y red objetivo para estabilizar las actualizaciones. Esta técnica forma parte del temario propuesto en la consigna.

Entorno y preprocesado

- Gymnasium + ale-py con el entorno "ALE/Breakout-v5".

- AtariPreprocessing: reescalado a 84×84, escala de grises, *frame_skip* = 4 (en el *wrapper*, dejando el *env* base en frameskip=1), noop_max=30, y terminal_on_life_loss=False.
- FrameStackObservation con stack_size=4 para aportar información temporal.
- Monitor para registrar métricas en monitor.csv (recompensa r, longitud l, tiempo t).
  Este *pipeline* disminuye la dimensionalidad, acelera el aprendizaje y asegura compatibilidad con SB3.

DQN

- Librería: Stable-Baselines3.
- Política: CnnPolicy estándar de SB3 para Atari.
- Hiperparámetros:

  buffer_size=100_000, learning_starts=10_000
  train_freq=4, target_update_interval=1_000
  exploration_fraction=0.10, exploration_final_eps=0.01
  Optimizer y learning_rate=1e-4

- Presupuesto de entrenamiento: total_timesteps=20_000_000.

Resultados

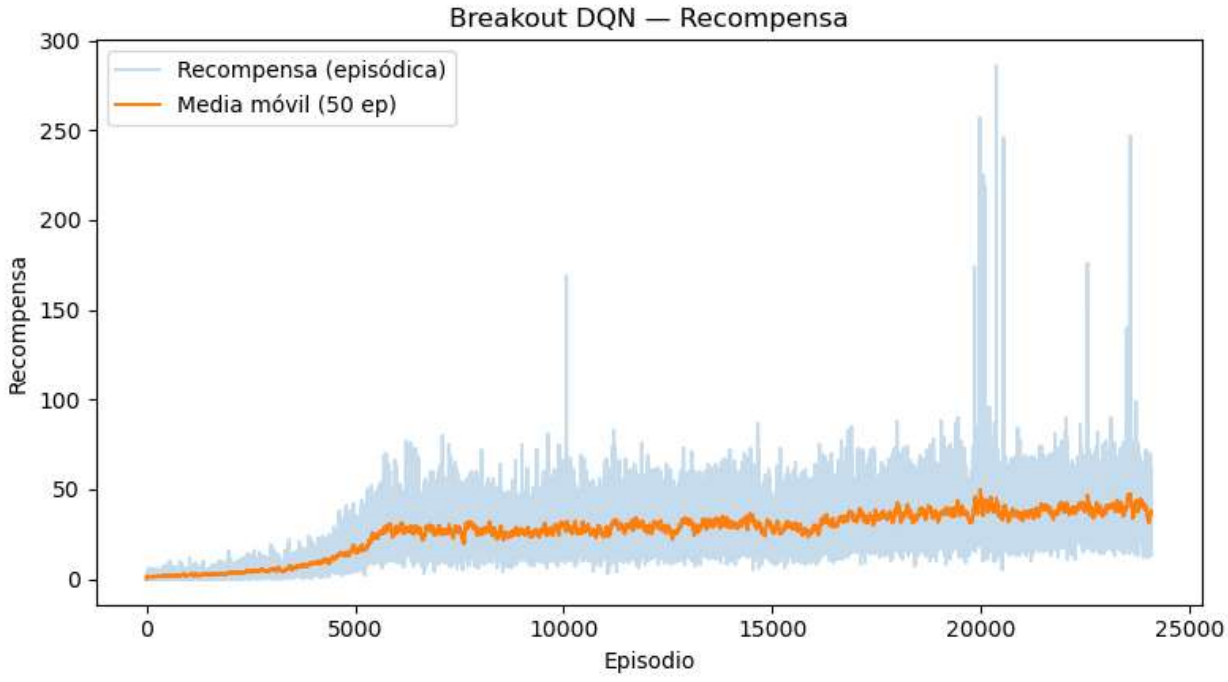

Entrenamiento (SB3)
Al inicio (≤ ~12k *steps*):

- ep_rew_mean ≈ 1.0–1.6, ep_len_mean ≈ 176–204, exploration_rate ≈ 1.0

Cerca del final (≈ 20M *steps*):

- ep_rew_mean ≈ 34.8–35.4, ep_len_mean ≈ 1.00–1.01e3, exploration_rate ≈ 0.01.
- Actualizaciones totales ≈ 5.0M, *loss* estabilizado ~7e-3.

- Recompensas observadas: 28.0, 45.0, 27.0 y 39.0, 22.0, 16.0 (múltiples corridas).

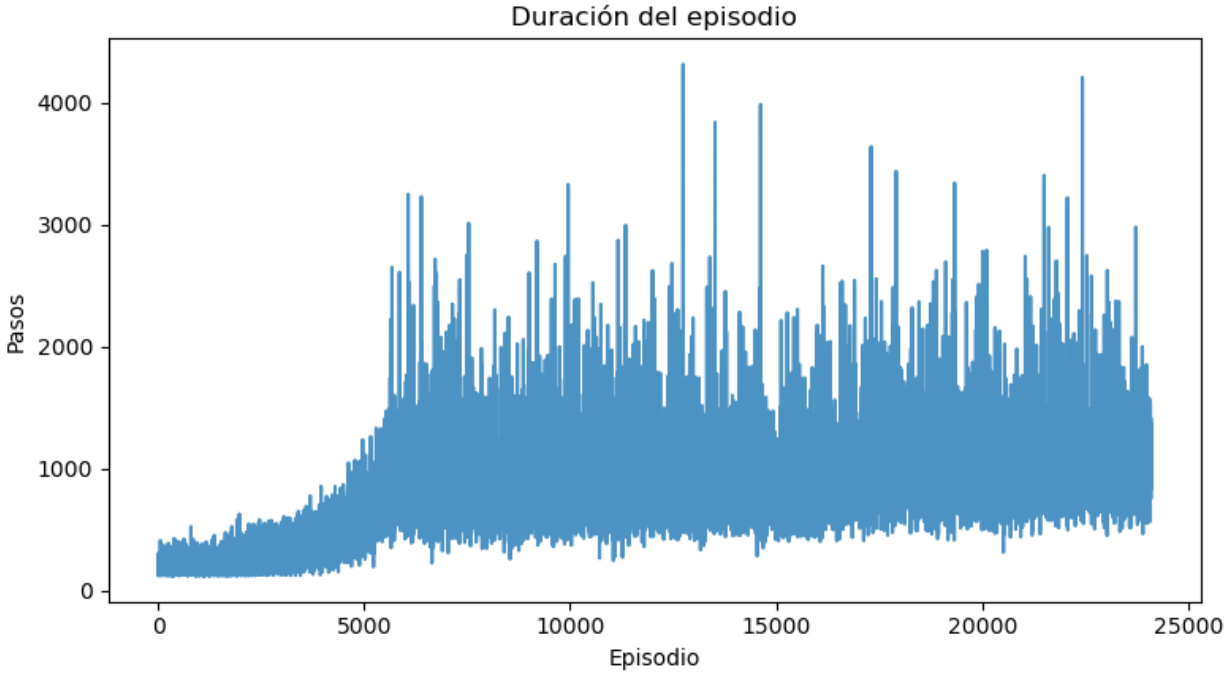

Interpretación:

- La tendencia creciente de la recompensa y la estabilización del *loss* sugieren que el agente aprendió.
- El aumento de longitud de episodio se correlaciona con mayor control de la pelota.

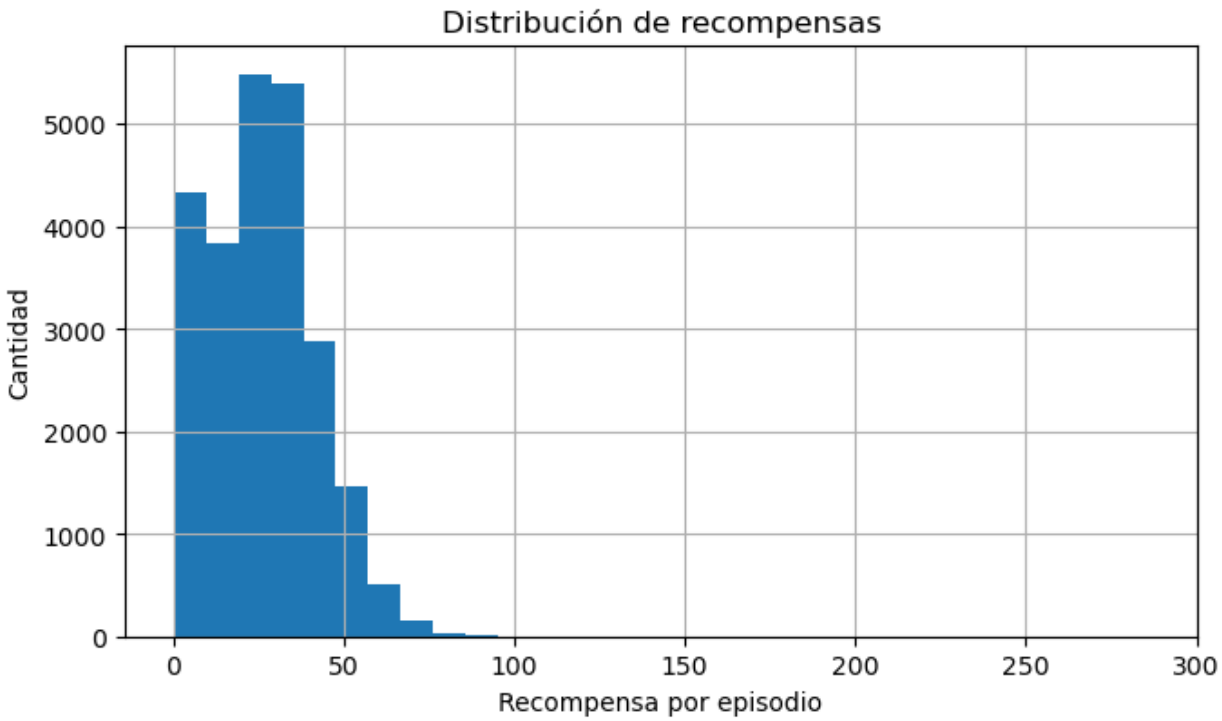

Conclusiones

El agente DQN entrenado con preprocesado estándar de Atari y una política CNN mejoró su desempeño, alcanzando una recompensa promedio por episodio ~35 tras 20M *timesteps*. La evidencia indica convergencia hacia una política estable que prolonga los episodios y acumula mayor retorno.